

Análise Visual de Erros de Ponto Flutuante e das *Units of Last Place* em Experimentos Computacionais

Ribas, E. R. L. D.¹, D'Afonseca, L. A.², Rocha, L. M.³
 CEFET-MG, Belo Horizonte, MG

Este trabalho apresenta resultados de estudos realizados em um projeto de iniciação científica e tem como objetivo explorar graficamente alguns efeitos do cálculos realizados com ponto flutuante e das Unidades de Última Posição (*Units of Last Place*).

Um Sistema de Ponto Flutuante (SPF) é a maneira utilizada para aproximar números reais pelos computadores através de representações binárias compactas. Devido à natureza discreta e finita dos SPF's, erros de representação são intrínsecos e propagam-se em operações aritméticas sucessivas, se acumulando e podendo comprometer severamente a exatidão numérica do sistema. Um número representado em ponto flutuante em computadores é então calculado como

$$x = (-1)^s \times \left(1 + \sum_{i=1}^{t-1} (d_i \times \beta^{-i}) \right) \times \beta^p, \quad (1)$$

onde s é o *bit* de sinal, d_i são os dígitos significativos, p é o expoente, β é a base e t é o número de dígitos significativos. O expoente é armazenado com um viés (*bias*), ou seja, o valor real do expoente é calculado como $P = p + \text{bias}$, onde P é o valor armazenado e *bias* é um valor constante que depende do formato de precisão utilizado. O sistema para 64 *bits*, utilizado na maioria dos computadores atuais, é definido por $\beta = 2$, $t = 53$, $L = -1022$, $U = 1023$ e *bias* = 1023 em que L e U são os limites inferior e superior do expoente, respectivamente.

O padrão definido pela IEEE-754 [4] formaliza essa arquitetura, alocando *bits* para sinal, expoente e mantissa em precisões simples (32 *bits*) e dupla (64 *bits*), como representado na equação (1).




Figura 1: Gráfico da Função $ULP(x^{23})$ num SPF IEEE de 64 bits. Fonte: Autor.

¹enzorochaletedinizribas@gmail.com

²luis.dafonseca@gmail.com

³lucasmartinsrocha@gmail.com

A *Unit of Last Place (ULP)* é a menor diferença entre dois números representáveis em ponto flutuante, ou seja, a distância entre um número e o próximo número representável [1, 2]. O conjunto de números se torna mais esparsos quanto mais distante o número for de zero, aumentando o erro relativo. Dessa forma, a ULP se torna uma medida relativa importante para avaliar a precisão dos cálculos realizados com ponto flutuante, podendo ser calculada como

$$\text{ULP}(x) = \beta^{p-t+1}, \quad (2)$$

Um erro comum em SPF's é o da perda de significância, ou cancelamento catastrófico, que ocorre quando é realizada uma operação com dois números muito próximos ou de grandezas muito diferentes, resultando em um valor com menos dígitos significativos do que os números originais, devido ao alinhamento de mantissa. Um exemplo desse comportamento é observado na função $f(x) = x^{23} + 1 - x^{23}$, que é igual a 1. Porém, ao avaliar f usando ponto flutuante, obtemos o gráfico da Figura 2, em que o valor correto é exibido apenas até x próximo de 4,9. A partir de aproximadamente $x = 5,1$, a função assume o valor zero. Isso ocorre, pois o valor x^{23} é muito maior que 1, o que resulta na perda de significância, produzindo $x^{23} + 1 = x^{23}$.

Entre 4,9 e 5,1 observamos a ocorrência de uma oscilação caótica relacionada com o valor da $\text{ULP}(x^{23})$, que é 2. Para realizar a soma $x^{23} + 1$, o SPF precisa representar os dois números na mesma potência. Porém, o valor do expoente necessário para representar x^{23} está associado à uma ULP igual a 2, em que o número 1 não pode ser representado e precisa ser arredondado. Esse arredondamento faz com que $x^{23} + 1$ seja igual a x^{23} ou $x^{23} + 2$, produzindo a oscilação observada.




Figura 2: Resultado da avaliação da função $f(x) = x^{23} + 1 - x^{23}$ num SPF IEEE de 64 bits. Fonte: Autor.

O fenômeno observado destaca a importância do conhecimento sobre o sistema utilizado por máquinas ao realizar cálculos que necessitam de precisão, como os comumente utilizados por métodos numéricos (vide [3]).

Referências

- [1] William Kahan. “A logarithm too clever by half”. Em: **Unpublished note** (2004).
- [2] Jean-Michel Muller. “On the definition of $\text{ulp}(x)$ ”. Em: **CNRS – Laboratoire LIP, projet Arinaire** (2005).
- [3] Márcia Aparecida Gomes Ruggiero e Vera Lúcia da Rocha Lopes. **Cálculo numérico: aspectos teóricos e computacionais**. Sao Paulo: Pearson/Makron, 1998.
- [4] IEEE Computer Society. **IEEE Standard for Floating-Point Arithmetic**. 2019.